

Cursul 9

Stocarea și prelucrarea datelor

Utilizarea Sistemelor de Operare (USO)

20 noiembrie 2017

Departamentul de Calculatoare

Citat

Three things are certain:
Death, taxes, and lost data.
Guess which has occurred.

David Dixon, 1998, winning entry of the Haiku Error Messages 21st Challenge

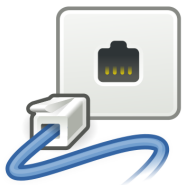


adresă IP

mască de rețea

gateway

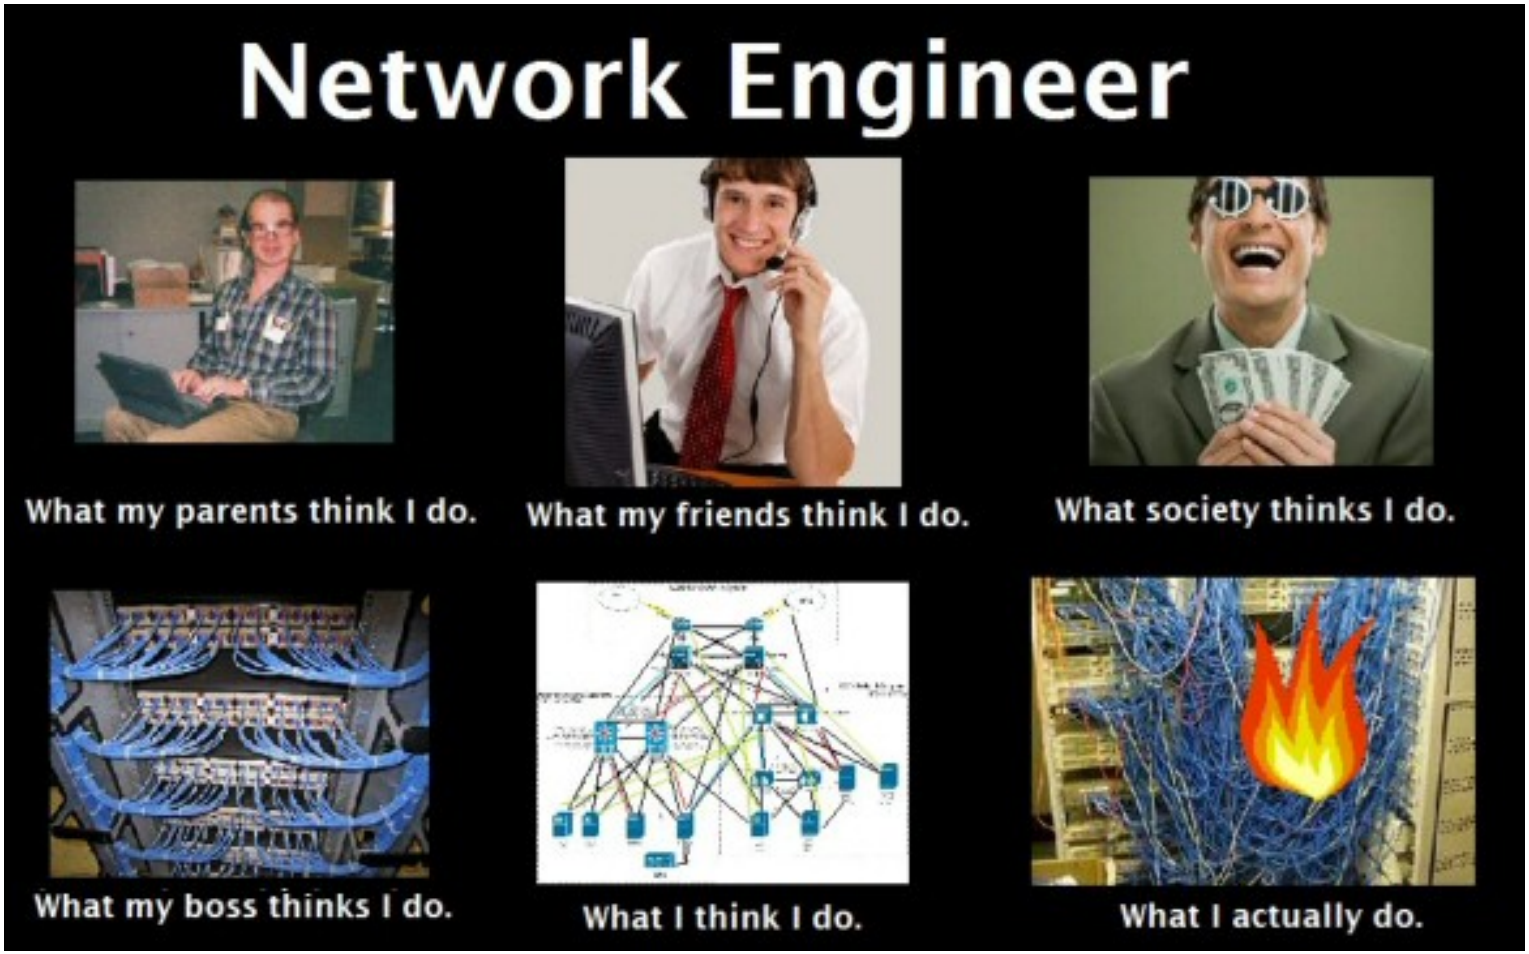
server DNS



	static	dinamic

temporar	`ip address add 192.168.0.2/24 dev eth0`
	`ip route add default via 192.168.0.1`
	`echo "nameserver 8.8.8.8" > /etc/resolv.conf`
		`dhclient eth0`

persistent	**/etc/network/interfaces**
	`auto eth0`
	`iface eth0 inet static`
	`address 192.168.0.2`
	`netmask 255.255.255.0`
	`gateway 192.168.0.1`
	`dns-nameserver 8.8.8.8`
		`auto eth0`
		`iface eth0 inet dhcp`



http://www.guy-sports.com/humor/computers/computer_tech_support_calls.htm

În această săptămână la USO

- în week end apare quest de World of USO
- miercuri, 22 noiembrie 2017, începe laboratorul 9: Stocarea și prelucrarea datelor
- tema 3 va apărea în această săptămână
  - întrebați, întrebați, întrebați
  - folosiți forumul
  - ajutați colegii pe forum
  - `https://ocw.cs.pub.ro/courses/uso/regulament`
    - secțiunea ,,Recomandări de comunicare electronică”
    - secțiunea ,,Realizarea temelor”
- slide-urile cursului 10: ,,Shell scripting” vor fi publicate vineri, 24 noiembrie 2017

Pin-uri USO

58 de pin-uri

- **lab**: 18 pin-uri (votat de asistenți)
- **curs**: 8 (separat pe fiecare serie: 2 CA, 2 CB, 2 CC, 2 CD)
- **midterm**: 8 (primele 8 scoruri la testul practic de midterm)
- **final**: 16 (separat pe fiecare serie: 3 CA, 3 CB, 3 CC, 3 CD), cel mai bun scor, primul scor la practic, primul la grilă
- **extra**: 8 (per serie), cea mai activă persoană din serie pe forumuri (cs.curs.pub.ro), cel mai activ om în zona de social media (postări cu #usolife)

`https://systems.cs.pub.ro/bachelor/uso/2018`

Cuprins

Date digitale

Baze de date. SQL

Prelucrări de date

Parsarea datelor

Prezentarea datelor

Sumar

Extra

- informații stocate pe suport electronic (în general discuri)
- se stochează digital (în biți, specific sistemului de calcul)
- în general stocate în fișiere, în cadrul sistemelor de fișiere
- avantaje față de date ,,nedigitale'':
  - stocare facilă (nu ai nevoie de spațiu fizic)
  - duplicare instant (nu e nevoie de copiator sau scanner)
  - transfer ușor (nu ai nevoie de cutii și camioane)
  - controlul accesului (decizi cine ce folosește)
  - aplicații care folosesc date (aplicații conform nevoii: criptare, extragere informații, înlocuire etc.)
  - format de stocare (binar, text, comprimat etc.)

Ce e important la date digitale?

- spațiul ocupat: unde le stocăm, cum le stocăm
- accesul: cum le accesăm, ce interfețe oferim, ce aplicații le folosesc
- securitatea: cine are acces, cum protejez de acces nedorit
- permanența (backup, versionare): cum previn pierderea datelor

- datele structurate sunt organizate, în general, ca o listă de elemente ce respectă niște criterii
- lista de studenți dintr-o facultate și atributele lor reprezintă date structurate
- catalogul unei materii e o formă de informație structurată
- alte exemple
  - lista angajaților unei companii
  - portofoliul de produse al unei companii
  - istoricul de evenimente ale unei organizații

Entități, proprietăți și asocieri

- în datele structurate folosim entități (persoane, studenți, evenimente, produse)
- entitățile au proprietăți sau atribute
  - o persoană are vârstă, sex, înălțime, ocupație, dată de naștere
  - un eveniment are o dată de desfășurare, un organizator, un set de sponsori, niște obiective
  - un produs are un nume, un producător, un preț, un mod de distribuție
- entitățile pot fi legate sau asociate între ele
  - un profesor predă mai multe cursuri
  - un curs este parte a unui an de studiu
  - un an de studiu cuprinde mai multe serii
  - seriile conțin studenți
  - o persoană are ca părinți alte persoane
  - o persoană lucrează într-o organizație
  - o organizație furnizează o serie de produse
- formele de stocare a datelor structurate trebuie să păstreze entitățile, atributele acestora și legăturile/asocierile între ele

Date în format tabelar

- un mod de prezentare a datelor structurate este formatul tabelar: linii și coloane
- fiecare tabelă reprezintă o entitate (de exemplu ,,studenti")
- fiecare linie din tabel reprezintă o intrare, un element de tipul acelei entități (adică un ,,student" real)
- fiecare coloană înseamnă atribute ale studentului (nume, grupă, notă, username, locul nașterii etc.)
- pot exista referințe între tabele; o coloană este o referință către altă intrare din alt tabel sau din același
- fișierele spreadsheet (.xls, .ods) sunt forme de date structurate în format tabelar

Baze de date

- mod de structurare a datelor pentru stocare și accesare eficientă
- orice formă de structurare a informației pentru a facilita accesul poate fi considerată o bază de date
- poate fi text sau binar
- `/etc/passwd`: baza de date de utilizatori locali
- în general, baza de date este binară pentru eficiență

Format text

- citibil, format ASCII
- ușor de editat și parcurs
- foarte portabil
- spațiu ocupat mai mare
- util pentru fișiere relativ mici, ce pot fi parcurse de oameni
- în general nu foarte divers, folosim cuvinte și caractere

Format binar

- nu poate fi inspectat de o persoană
- nevoie de o aplicație dedicată pentru citire și modificare
- posibil să fie dificil de deschis cu altă aplicație
- eficient ca spațiu
- poate folosi fișiere oricât de mari
- flexibilitate completă la modul de structurare

Serializare

- transformarea structurilor de date/obiectelor într-o formă stocabilă (de obicei un fișier)
- în general se preferă un format de stocare standard, care să poată fi folosit de diverse aplicații/limbaje
- exemple de formate de stocare de date serializate text: JSON, XML, YAML
- în Python se poate folosi modulul Pickle care stochează date în fișiere binare

Date în format atribut-valoare

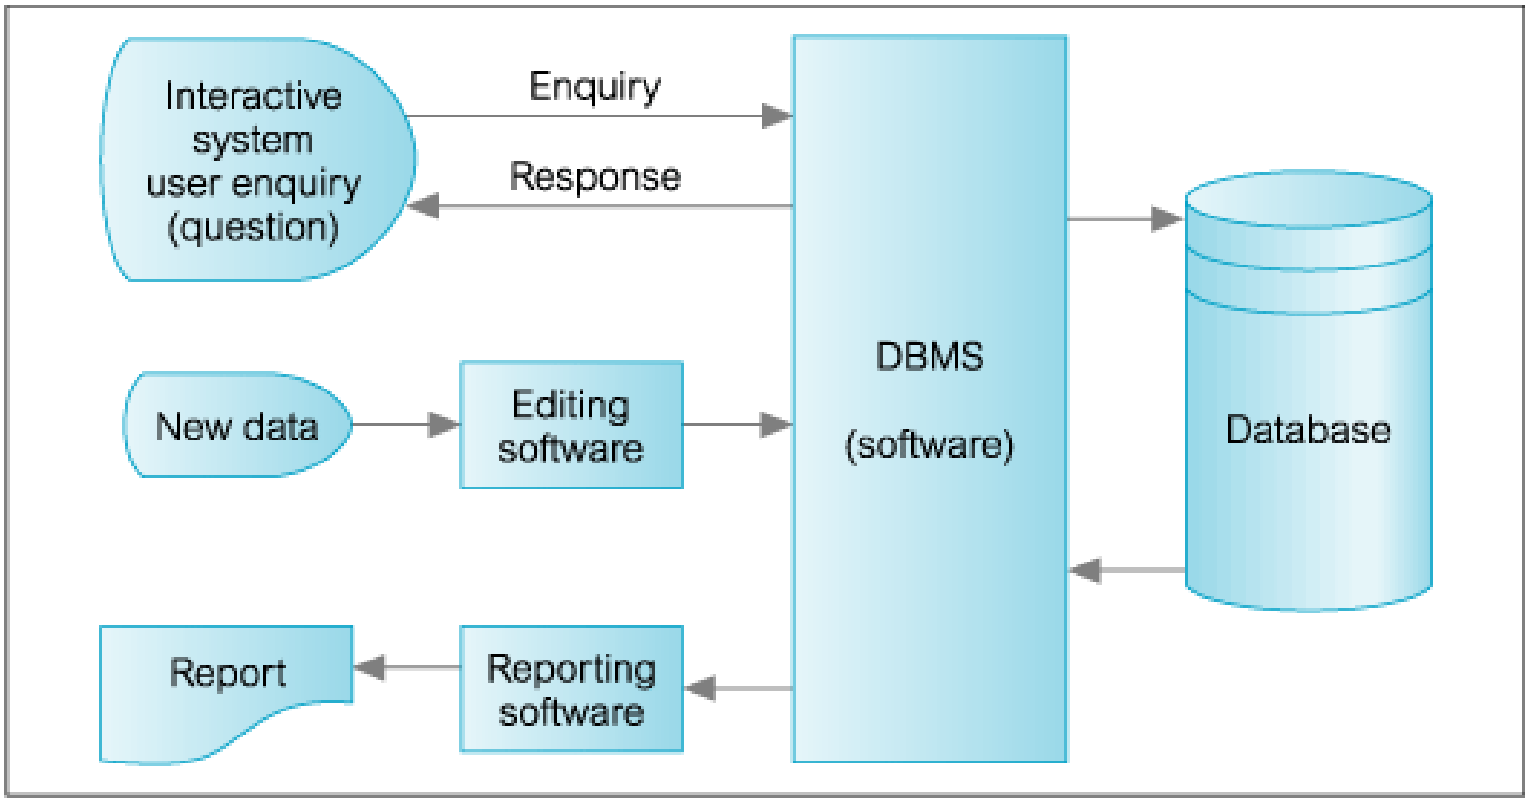
- nu există obiecte/entități, ci doar proprietăți/atribute și valori pentru acestea
- în general de forma `attribute = value` sau `attribute: value`
- util pentru fișiere de configurare, nu pentru obiecte sau entități
- `/etc/default/grub`, `/etc/hosts`, fișierele `.vmx`

- INI: formă simplă de cheie valoare
- JSON (*JavaScript Object Notation*): o formă de definire de obiecte (cu atribute și valori)
- YAML (*YAML Ain't Markup Language*): este un superset al JSON
- XML (*Extensible Markup Language*): reprezentare arborescentă
- CSV (*Comma Separated Values*): format tabelar text, colaborare cu suite Office

- codificarea caracterelor folosite de oameni în format digital de reprezentare
- ASCII asociază 7 biți pentru fiecare caracter: `A = 0x41`, `a = 0x61`
- UTF-8 este cel mai răspândit format de codificare din Internet
- UTF-8 este compatibil cu ASCII și permite reprezentarea unui spectru larg de caractere
  - în UTF-8: `ș = 0xc899`, `ț = 0xc89b`
  - caractere chirilice, chinezești etc.

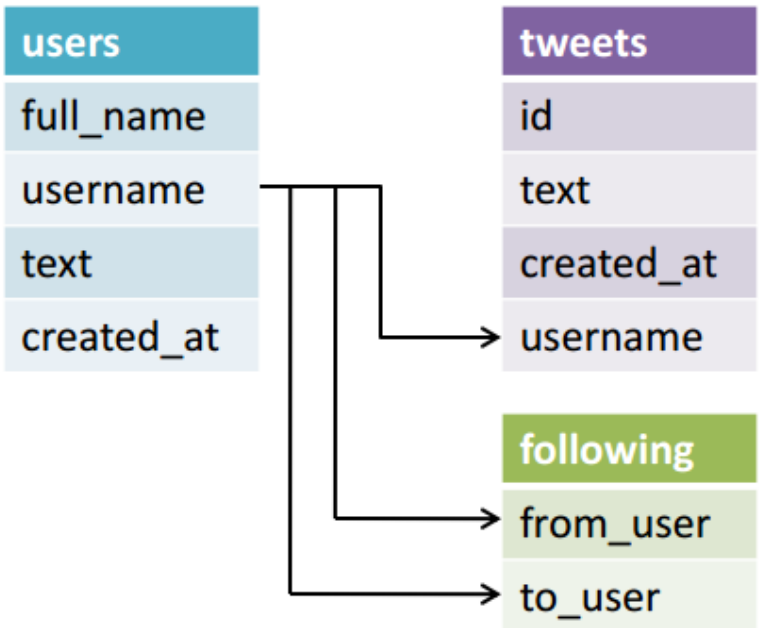
Ce este o bază de date?

- un fișier sau un set de fișiere
- format particular de stocare, specific implementării
- în general binare cu un nivel de acces la baza de date
- sisteme de gestiune a bazelor de date pentru interacțiune cu baza de date (SGBD, DBMS)
- pentru o bază de date definim o schemă: modul de organizare și legătură
  - practic implementarea modelului entitate-asociere
- în general, modelelul relațional (pe bază de tabele): RDBMS - *Relational Database Management System*



http://resources4ict.excellencegateway.org.uk/term.php?id=1192&img=1

- interfața expusă în formă de tabele
- model cu intrări (rânduri) cu proprietăți (coloane) și legături între ele
- formele de interogoare țin cont de stuctura pe bază de tabele
- cele mai cunoscute SGBD sunt de tip relațional: Oracle, MS SQL, IBM DB2, MySQL, MariaDB, PostgreSQL, Firebird, SQLite



http://code.tutsplus.com/tutorials/relational-databases-for-dummies--net-30244

- creează un tabel
- șterge un tabel
- adaugă o intrare
- șterge o intrare sau mai multe
- selectează o intrare sau mai multe
- actualizează o intrare

- *Standard Query Language*
- limbaj dedicat pentru interogarea unui RDBMS
- sintaxă simplistă pentru interacțiune cu baza de date

Comenzi SQL

```
insert into studenti(nume, email, an, serie)
    values('Capota Paul', 'paul.capota@gmail.com', 2, 'CC');

delete from students where nume='Capota Paul';

select from students where serie='CC';

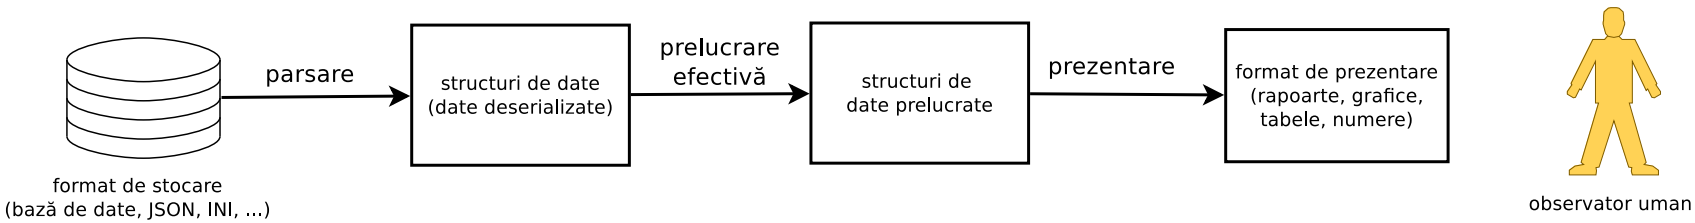
update students set serie='CA' where email='paul.capota@gmail.com';
```

Ce vrem să facem cu datele?

- vizualizare, interpretare, analiză, rapoarte: în general în forma de imagini și grafice
- sumarizare, agregare, statistici: în general în formă numerică
- căutare, selectare, sortare, ordonare, grupare, extragere: în general în formă de tabele sau liste
- datele sunt prelucrate prin mijloace (*means*) pentru a atinge obiective (*ends*) observatorului uman
- ne preocupă obiectivele și alegem mijloacele cele mai potrivite

- *data processing*, *data analysis*
- metodele prin care datele sunt preluate de pe suportul de stocare și apoi analizate pentru a obține un rezultat util observatorului
- rezultatul poate fi un număr, un tabel, un grafic
- metodele de prelucrare depind de
  - modul de stocare
  - tipul datelor (numere, șiruri, array-uri)
  - nevoile observatorului uman

Pași în prelucrarea datelor



Best tool for the job

- plecăm de la obiective (*ends*, ce vrem să obținem) și apoi stabilim mijloacele (*means*, cum vrem să ajungem acolo)
- *means to an end*
- în funcție de situație alegem o opțiune sau alta
- **stocare**: text sau binar, JSON sau XML, XML sau baze date, date tabelare sau nu
- **parsare**: utilitare simple (`cut`, `awk`, shell scripting), funcționalități în limbaje (Python, C, Java), aplicații dedicate (lexere, Flex), interfața SQL pentru baze de date
- **prelucrare**: shell scripting, limbaje de programare dedicate
- **prezentare**: numere, tabele, grafice

Exemple de scenarii

- dorim să indexăm numele de funcții și variabile globale dintr-un fișier cod sursă (sau mai multe)
- dorim să parcurgem un fișier CSV (*Comma Separated Values*)
- dorim să parcurgem informațiile dintr-un fișier de tip jurnal (*log*), unde fiecare linie are o intrare specifică
- dorim să analizăm și să extragem informații dintr-un fișier XML
- dorim să intepretăm datele dintr-o bază de date SQL (de obicei engine-ul SQL face parsarea)

Splitting, tokenizing, parsing, deserializing

- în sensul larg, *parsing* se referă la analiza sintactică a unui text
- un *lexer* sau *tokenizer* împarte un text în elemente (*items*); este folosit de parser
- *splitting* e o formă simplă de parsing în care se împarte un text în elemente ținând cont de un caracter sau de un set de caractere despărțitoare (separator de câmpuri – *field separator*)
- *deserializarea* este o operație generalistă: se referă la transformarea datelor din suportul de stocare în structuri de date în memorie (liste, array-uri, arbori etc.)
  - operația de stocare a datelor din memorie într-un suport de stocare se numește *serializare* (numită și *marshalling*)

Date tabelare

- linii (*rows*) și coloane (*columns*)
- există un separator de câmpuri (de coloane): *field separator*
- separatorul de linii este caracterul *newline* (linie nouă, `\n`)
- parsarea se referă în general la împărțirea câmpurilor/coloanelor de pe fiecare linie (*splitting*)

Separatorul de câmpuri

- *field separator* sau *field delimiter*
- împarte câmpuri pe o linie
- poate fi un caracter (virgulă, tab, spațiu) sau un set de caractere (semne de punctuație)
- utilitarele care fac split precizează caracterul sau setul de caractere pentru separare
  - opțiunea `-d` la `cut`
  - opțiunea `-F` la `awk`
  - opțiunea `-s` la `sort`
  - `string.split()` în Python
  - `String.split()` în Java

cut vs. awk

- `cut -d ' ' -f 1`
- `awk -F '[ ]' '{print $1;}'`
- `cut` e mai simplu
- `awk` permite folosirea unei expresii regulate pe post de separator
- `awk` are și alte utilizări în afară de *splitting*
- pentru cazuri mai complexe folosim limbaje de programare

Ce prezentăm?

- evoluții, reprezentări grafice: imagini
- medii, erori, contoare: numere
- liste cu primele N valori, primele N caracteristici: tabele, rapoarte

- medii (în general aritmetice): a tuturor valorilor, a unor valori
- contoare: câți studenți au obținut nota X, câte persoane s-au născut în anul Y
- abaterea pătratica medie (dispersia)
- variații: cât a crescut consumul de lapte în perioada X

- de obicei agregări de prezentări numerice
- asocieri
- datele complete despre parlamentarii care au votat legea X
- grupa și media pe grupă pentru materia X

- pornesc tot de la numere
- grafice cu puncte (*plots*)
- grafice cu linii
- grafice cu linii și puncte (legături între puncte)
- histograme (distribuția de valori numerice)
- bar charts (similar cu histograme, dar distribuția poate fi și după alte criterii: țări, perioade, localități)
- pie charts (grafice de tip plăcintă cu felii/procente)

Utilitare pentru prezentare grafică

- aplicații spreadsheet în suite Office
- gnuplot
- Matlab / Octave
- matplotlib
- R
- `http://en.wikipedia.org/wiki/Wikipedia:How_to_create_charts_for_Wikipedia_articles`

Ce folosești când stochezi date?

- text: pentru configurare și pentru date în fișiere mici
- INI: pentru configurare foarte simplă
- YAML: pentru configurare mai complexă, pentru date de mici dimensiuni
- JSON: pentru interacțiune cu servicii web
- XML: pentru configurări foarte complexe, pentru extensibilitate
- fișiere binare simple: pentru eficiență și viteză
- baze de date: date de mari dimensiuni, nevoie de căutare și de viteză, aplicații accesează concurent

Sfaturi în prelucrarea datelor

- întâi obiectivele (prezentare, finalitate, *ends*) înainte de mijloace (parsare, prelucrare efectivă, *means*)
- best tool for the job: accesibil, rapid, mentenabil
- depinde de formatul de stocare (text, binar, XML, bază de date)
- nu reinventați roata; folosiți ceea ce deja există
- o imagine face cât o mie de cuvinte

Cuvinte cheie

- date digitale
- structurate
- nestructurate
- entitate
- proprietate
- asociere
- format tabelar
- format text
- format binar
- atribut-valoare

- INI
- JSON
- YAML
- XML
- CSV
- bază de date
- SGBD, DBMS
- relațional
- RDMBS
- interogare
- SQL
- prelucrări

Resurse utile

- http://www.yaml.org/
- http://www.w3.org/XML/
- http://www.json.org/
- http://www.fileinfo.com/filetypes/spreadsheet
- https://www.dmoz.org/Computers/Data_Formats/Database

Rackspace

- companie de hosting IT
- fondată în 1996
- unul dintre principalii furnizori de servicii cloud (`Rackspace Cloud`)
- contribuitor la OpenStack
- folosit de GitHub

Big Data

- termen care definește date neprelucrabile în modul standard
- mari, complexe: meteorologie, finanțe, căutare pe Internet
- date de ordinul PB, ZB
- operații obișnuite pe alte date: căutare, prelucrare
- necesită sisteme capabile de calcul paralel/distribuit sau alte abordări